

令和5年
修士論文草稿

Biterm Topic Modelを用いた
SNS上の商品レビューに対する関連性
評価

指導教員：相馬 隆郎

東京都立大学大学院
電子情報システム工学域

学修番号：22861651

氏名：西原涼介

論文要旨

近年, Amazon や楽天市場などの大手 EC サイトをはじめ, 数多くの EC サイトが普及しその利用者数は急速に増加している. EC サイトの利用者のうち, 約 70%が商品を購入する際に EC サイトのレビューを参考にしているとされ, その中でも特にレビューの信頼性を重要視している人が多いことが明らかになっている. また, 多くの企業にとっては EC サイトのレビューからユーザーの嗜好や意見を分析し, マーケティングに活用することが重要な課題となっている. そのため, EC サイトのレビューの信頼性や有用性を評価する評判分析や口コミ分析, レビューを様々なトピックに分類する文書分類に関する研究が多く行われている. 例えば, Amazon の商品レビューを機械学習を用いて分析し, 他のユーザーにとって参考になる順に並び替えるシステムの構築及びその評価に関する研究や, グルメサイトの口コミにおいて実名・顕名・匿名の違いがレビューの信頼性に与える影響についての研究などが挙げられる. また近年では, 従来の EC サイトや商品の Web ページだけではなく, YouTube のような動画投稿サイトや X(旧 Twitter) や Instagram などの SNS を自社製品やサービスの宣伝の場として利用している企業が増加している. これに伴い, 商品を購入する際に SNS や YouTube 上でその商品を宣伝している投稿を参考にしている人も増加している. そのため, SNS や YouTube 上の広告に対するユーザーのコメントも, 他のユーザーが商品の購入を検討する際の重要な判断材料になり得ると考えられる. つまり, SNS や YouTube 上での商品の宣伝に対するコメントは, EC サイトの商品レビューと同等の機能を持ち, その信頼性や有用性が重要視されるため, 同じく評判分析や文書分類の研究の対象になると考えられる. 例えば, SNS や YouTube は商品レビューのページとは異なり, 誰でも気軽にコメントを投稿できたり, その投稿内容も自由という特性上, 商品やサービスに関係ないコメントが多数存在するという問題がある.

そこで, 本研究では分析対象を YouTube 上で自社製品やサービスを宣伝している動画に対するユーザーのコメントとし, その動画で宣伝している商品やサービスに対しての関連性が高いコメントを抽出するシステムの作成, 及び作成したシステムの人手に対する精度の検証を目的としている. これにより, EC サイトの商品レビューと同様に他のユーザーが商品の購入を検討する際の重要な判断材料として扱うことが可能になると考えられる.

この目的の実現のため, 本研究ではトピックモデルの一種である Bitern Topic Model(BTM) を用いたトピック抽出, 及び各トピックの生成確率上位の単語を利用した手法を提案する. BTM は他のトピックモデルとは異なり, 文書全体のバイターム (2 単語の対) の共起性を利用してトピックを学習するため, YouTube のコメントのように一文が比較的短い場合でも適切にトピックを推定することが可能であると考えられる. 以下に本研究の提案手法の概要を述べる. はじめに, 商品やサービスの宣伝を行っている YouTube 動画に対するコメントを YouTube Data API を用いて取得し, クリーニング処理や分かち書きなどの前処理を施す. 次に, 前処理をしたコメント集合に BTM を適用し, 潜在的なトピックの推定と各トピックにおける生成確率上位の単語を抽出する. そして, 大規模言語モデルである GPT-4 を用いて, 各トピックから抽出した単語を基に文章を自動的に生成する. ここで生成した文章は BTM によって推定したトピックに出現しやすい単語を用いているため, 各トピックの代表的な文章であるという仮説を立てることができる. つまり, 生成した文章は元のコメント集合に対して代表的であり, 動画内容に関連している文章であるという仮説が立つ. その仮説を基に, 各トピックごとに生成した文章と元のコメント文との文章間の類似度を計算し並び替えることで, 本研究の目的である動画に対して関連性が高い文章の抽出が実現できると考えた. また, 本仮説の妥当性, 及びシステムの精度を検証するために, 人手でアノテーションしたデータセットとの比較分析を行った.

実際の YouTube コメントを本手法に適用し実験を行なった結果, BTM によって商品に関連し

ているトピック及び単語を適切に抽出することができた。また、人手でアノテーションしたデータと本手法で類似度計算を行ったデータから Confusion Matrix を算出し、様々な指標で本手法の性能を評価した。その結果、Precision(適合率) が 0.7 程度の値を示したことから、本手法により商品との関連性が高いと予測したコメントのうち約 7 割が人手の評価に対して正しく予測できていることが分かった。この結果より、本研究で提案した SNS や YouTube コメントに対する新たな分析手法の有効性を示すことができた。

目次

第 I 部 はじめに	4
1 研究背景	4
2 関連研究	5
2.1 機械学習を用いた自然言語処理による商品レビューの評価 [1]	5
2.2 単語の出現頻度と類似性に基づいたトピックモデル洗練化手法 [2]	7
2.3 関連研究 3	9
3 研究目的	10
第 II 部 提案手法	11
4 トピックモデル	11
4.1 Latent Dirichlet Allocation	11
4.2 Biterm Topic Model	11
5 提案手法	12
5.1 データ収集	12
5.2 前処理手法	13
5.2.1 クリーニング処理	13
5.2.2 MeCab による形態素解析及び分かち書き	14
5.3 BTM によるトピック抽出	16
5.4 文章生成	17
5.5 文章間の類似度計算	18
5.5.1 TF-IDF	18
5.5.2 BERT	19
5.6 提案手法の精度検証	20
第 III 部 実験結果	23
6 実験目的、仮説	23
第 IV 部 参考文献	23

第I部 はじめに

1 研究背景

近年, Amazon や楽天市場などの大手 EC サイトをはじめ, 数多くの EC サイトが普及し, その利用者も急増している. そして, 商品を購入する際に EC サイトのレビューを参考に行っている利用者の割合は約 70% と言われていて, その中でもレビューの信頼性を重要視している人が多いことが明らかになっている. また, 多くの企業にとって, EC サイトのレビューからユーザーの嗜好や意見を分析し, マーケティングに活用することが重要な課題となっている. そのため, EC サイトのレビューの信頼性や参考になるかどうかを評価する評判分析や口コミ分析, レビューを様々なトピックに分類する文書分類に関する研究が多く行われている. 例えば, 関連研究の項で詳しく紹介する「機械学習を用いた自然言語処理による商品レビューの評価」[1] では, Amazon の商品レビューを機械学習を用いて参考になる順に並びかえるシステムの構築, 及びその評価に関する研究を行っている. また近年では, 従来の EC サイトや商品の Web ページ以外にも, YouTube のような動画投稿サイトや X(旧 Twitter) や Instagram などの SNS で自社製品・サービスの宣伝を行う企業が増えてきている. それにつれて, 商品を購入する際に SNS や YouTube 上でその商品を宣伝している投稿を参考に行っている人も増加している. そのため, SNS や YouTube 上の広告に対するユーザーのコメントも, 他のユーザーが商品の購入を検討する際の重要な判断材料になり得ると考えられる. つまり, SNS や YouTube 上での商品の宣伝に対するコメントは, EC サイトのレビューと同等の機能を持ち, その信頼性や参考になるかどうかが必要になるため, 評判分析や文書分類の研究の対象になると考えられる. ここで, SNS や YouTube は商品レビューのページとは異なり, 誰でも気軽にコメントを投稿できたり, その投稿内容も自由という特性上, 商品やサービスに関係ないコメントが多数存在する.

そこで, 本研究では分析対象を YouTube 上で自社製品やサービスを宣伝している動画に対するユーザーのコメントとし, トピックモデルの一種である Biterm Topic Model による商品に関するトピック抽出を用いて, その動画に対するユーザーのコメントから, 宣伝している商品やサービスに対して関連性が高いコメントを抽出するシステムの作成, 及び作成したシステムの手対人の精度の検証を行った.

本論文の第 I 部では, EC サイトのレビューにおける評判分析やトピックモデルを用いた文書分類に関する関連研究の紹介, また本研究の研究目的を明確に説明する. 第 II 部では, 本研究で用いる二つのトピックモデルの説明, 及び提案手法のシステムや実装方法について説明する. 第 III 部では, 実際の YouTube 上の動画に対するコメントを用いた実験結果を述べる. 第 IV 部では, 実験結果をもとに考察した提案手法の有効性や将来性について述べる.

2 関連研究

本研究を進めるにあたり、研究テーマの方向性決めや研究課題の発見、及び本研究で用いている技術に関して参考にした論文を4つ紹介する。

2.1 機械学習を用いた自然言語処理による商品レビューの評価 [1]

この論文では、ユーザーが商品レビューを読んで参考になったかどうかを評価する機能が備わっていないECサイトの場合に、数多くあるレビューから参考になる情報を探す必要がある問題に着目し、機械学習を用いた自然言語処理の手法で分析、評価を行い、レビューを参考になる順番に並び替えるシステムの構築を目的としている。そして並び替えた順番が正しいかどうかを評価するために、クイックソートを利用した新しい評価法であるQE法を提案している。

図1はこの論文で提案されている、レビューを参考になる順番に並び替えるシステムの概要図である。はじめに、インターネット経由でAmazonの商品レビューのデータ取得し、学習用データと評価データに分ける。学習段階では、レビュー文章の正規化や各前処理を施し、教師データとして準備する。この研究では、全角数字やアルファベットを半角に変換したり、数字は全て0に置換、アルファベットは全て小文字に変換などの正規化を行っている。また、日本語形態素解析システムであるMeCabを用いて形態素解析を行い、品詞ごとに“_”で分割する。その後、活用語の原型への変換、及びストップワード除去を行っている。例えば、「ロボットは24時間働けるのでAIに仕事をとられる。」という文章の場合、正規化と前処理を施すことで、「ロボット_0_働ける_ai_仕事_とる。」となる。この一連の処理を学習用データに施した後、機械学習の際に用いる素性の抽出を行う。この研究はレビューを参考になる順序に並べ替えることが目的のため、素性には単語の出現



図 1: システム概要図 (出典：市川 [1] p.85)

頻度を用いている。目的変数をレビューが参考になる確率 P とし、抽出した素性を用いてロジスティック回帰により学習する。ロジスティック回帰のモデル式は式 (1) で示される。 θ_i は素性の重み、 N は素性の数を表している。

$$P = \frac{1}{1 + \exp(\theta_0 x_0 + \theta_1 x_1 + \cdots + \theta_N x_N)} \quad (1)$$

次に学習したモデルを用いて、評価用データに対して実験を行ない、提案システムの精度を検証している。この研究の提案システムの精度の評価は、実際の商品ページのレビューの並び順との一致率で評価している。正解の並び方を L_R 、提案システムによる並び方を L_P としたとき、それぞれの要素の一致率を P_{match} としている。例えば、以下の並び方のとき、 $P_{match} = 100\%$ となり最も良い結果となる。

$$L_R : \{1, 2, 3, 4, 5\}$$

$$L_P : \{1, 2, 3, 4, 5\}$$

しかし、以下のように並び方の評価としては良い結果と言える場合でも、5 件のレビュー中 1 件のみ一致していることになり、 $P_{match} = 20\%$ と低い結果になる。

$$L_R : \{1, 2, 3, 4, 5\}$$

$$L_P : \{4, 1, 2, 3, 5\}$$

このように正しい評価が行えない場合を解決するため、この研究ではクイックソートを利用した新しい評価法の QE 法 (Quicksort Evaluation method) を提案している。QE 法ではピボットを中央値とし、昇順にするために要素を入れ替えた回数 S_{count} と、要素数における最大の入替え回数 S_{max} を用いた式 (2) により、評価値 P_{QE} を求めている。なお、 S_{max} は全ての要素が逆順の場合にクイックソートで昇順に入れ替えた回数である。

$$P_{QE} = 1 - \frac{S_{count}}{S_{max}} \quad (2)$$

実際の商品レビュー 52,403 件を取得し、そのうち 51,403 件を学習用データ、1,000 件を評価用データに分けて実験を行い、提案システムの精度を評価した結果を表 1 に示している。ここで、登場回数 F とは学習の素性とするか決定するための単語の出現回数である。表 1 から、 $F = 5000$ 、学習率 $\eta = 1.7$ のときに評価値 $P_{QE} = 0.814$ と最大になる。従って、この論文で提案しているシステムはレビューを参考になる順序に並び替える手法として有効であると言える。

しかし、この論文では Amazon の商品レビューを分析の対象としていて、素性には単語の出現頻度を用いているため、提案システムが成り立つにはしっかり商品をレビューしている文章を学習させる必要がある。そのため、この論文で提案されているシステムでは YouTube で商品を宣伝している動画や、SNS の投稿に対するコメントを学習させた場合に上手く学習できなかったり、精度が悪くなってしまうことが考えられる。なぜならば、YouTube の動画や SNS の投稿に対するコメントというのは誰でも気軽にでき、内容も自由であるため、商品のレビューのようなコメントの数が Amazon の商品レビューに比べると少ないからである。また、一文の長さも短いことが多く、素性となり得る単語の抽出も難しいと考えられる。そこで、本論文ではそのような問題を解決するための手法を第 II 部で提案する。

表 1: 登場回数と学習率の組み合わせごとの評価値 P_{QE} (出典：市川 [1] p.91)

登場回数 F	素性数 N	学習率 η										
		1.0	1.1	1.2	1.3	1.4	1.5	1.6	1.7	1.8	1.9	2.0
100	2083	0.788	0.783	0.800	0.806	0.796	0.766	0.750	0.762	0.769	0.747	0.768
200	2083	0.788	0.783	0.800	0.806	0.796	0.766	0.750	0.762	0.769	0.747	0.768
500	1472	0.774	0.748	0.781	0.782	0.769	0.769	0.763	0.751	0.787	0.774	0.726
1000	1058	0.728	0.794	0.746	0.781	0.758	0.813	0.792	0.762	0.795	0.776	0.784
2000	701	0.782	0.756	0.781	0.712	0.737	0.734	0.722	0.800	0.795	0.769	0.718
5000	363	0.759	0.773	0.774	0.801	0.764	0.763	0.772	0.814	0.757	0.765	0.755
10000	207	0.795	0.804	0.795	0.809	0.789	0.782	0.794	0.781	0.741	0.787	0.759

2.2 単語の出現頻度と類似性に基づいたトピックモデル洗練化手法 [2]

この論文では, 第II部で後述するトピックモデルの一種の Latent Dirichlet Allocation(以下 LDA) を自然言語文書に適用する際の改善案を提案している. 通常, トピックモデルを自然言語文書に適用する際には, 前処理として分類に不必要なストップワードの除去を行うことが多いが, 一般的にストップワードリストに含まれている単語を除去するだけでは, 特定の文書にのみ頻出する特徴的な単語を除去することが出来ず, トピックモデルの精度に影響を及ぼすという問題が存在する. また, トピックモデルによって分類したトピックには, 類似したトピックが複数出現し, 分類の精度が下がるという問題も存在する.

そこでこの論文では, 前処理として分析対象としている文書から適切なストップワードリストを作成する方法を提案している. また, トピックモデルを適用後の後処理として, トピックを構成している単語の類似度からトピック間の距離を算出し, 類似しているトピックを統合することでより正確なトピック分類を可能にする手法を提案している. 図 2 は提案手法の全体像である.



図 2: 提案手法の流れ (出典：東 [2] p.27)

ストップワードリストを作成する手順を図 3 で示している. この手法では, まず対象としている文書全体に対して出現率が高い単語をストップワードとして抽出する. 出現率の算出には DF(Document Frequency) を用いている. DF とは, 文書全体に対してある単語 T が含まれる文書数のことであり, 事前に設定した閾値よりも高い DF 値を持つ単語をストップワードリストに加える. 次に, 抽出した単語と意味的に類似している単語をさらにストップワードとしてリストに加える.

る. word2vec を用いて文章中の各単語を周辺の単語から学習し, 単語の分散表現を得て単語間の類似度を算出する. それによりある単語 T の類似単語を抽出することができ, ある閾値以上の類似度を示した単語を全てストップワードリストに加える. これにより, DF 値が高くない場合でも文書の特徴を表しにくい単語をストップワードリストに加えることが可能になる.



図 3: ストップワード抽出手法の流れ (出典: 東 [2] p.27)

トピックモデル適用後の後処理では, 分類結果に似たよったトピックが存在する場合にそれらのトピックを統合する処理を行うことを提案している. 類似トピックの判断基準には, TF-IDF \cos 類似度推定法が用いられている. これは, \cos 類似度の計算に使用するベクトルの成分を TF-IDF で算出したものにした手法である. この研究では, 分類した各トピックの単語集合に対して TF-IDF \cos 類似度を利用したクラスタリングを行い, その結果に従ってトピックを統合する手法を提案している.

以上の提案手法を LDA のよるメーリングリストのトピック分類に適用し, 評価項目に基づいて比較することで提案手法の有効性の評価を行っている. 評価項目として, 一般的なストップワードリストを用いた手法と提案手法を比較している. また, 後処理として類似トピックの統合を行った場合についても比較を行っている. トピック分類の正確さを評価する指標として, 適合率, 再現率, それらの調和平均の F 値を採用している. 実験結果を表 2 に示している. 表 2 より, LDA を自然言語に適用したトピック分類では, 前処理としてストップワード除去を行うことで分類精度が大幅に向上していることが分かる. また, 一般的なストップワードリストを用いた場合と提案手法によるストップワードリストを用いた方法を比較すると F 値が向上している. また, 後処理を行った場合の F 値はさらに向上していることから, トピック分類の正確性を向上させる提案手法の有効性を確認できている.

本研究ではトピックモデルの分類精度よりも抽出する単語の質を重視しているため, この研究で提案されているストップワードリスト作成方法を用いると抽出したい単語をストップワードリストに加えてしまう恐れがある. また, 本研究で分析の対象としている YouTube のコメントは, 書

表 2: ストップワード数 ($\#N$), 適合率, 再現率, F 値の結果 (出典: 東 [2] p.30)

	$\#N$	適合率	再現率	F 値
ストップワードなし	なし	0.047	0.497	0.086
Fox ストップ ワードリスト	425	0.237	0.397	0.297
Poisson ストップ ワードリスト	1238	0.355	0.422	0.385
RAKE	500	0.091	0.423	0.149
提案手法 (前処理)	761	0.411	0.418	0.414
提案手法 (前処理+後処理)		0.489	0.453	0.470

き言葉よりも話し言葉で書かれていたり, 若者言葉が使われていることが多く, 一般的なストップワードリストだけでは不要な単語を除去することが困難である. そのため, 前処理で形態素解析を行い, 特定の品詞のみ抽出してストップワードとして除去する, または特定の品詞のみでトピック分類を行う手法で実験を行った.

2.3 関連研究 3

関連研究 3 保留

3 研究目的

前項までの関連研究を踏まえた上で、本研究の研究目的を明らかにする。本研究では YouTube 上で商品やサービスを宣伝している動画に対する視聴者のコメントを分析対象とする。対象としているコメントのうち、その動画で紹介している商品・サービスと関連性が高いコメントを抽出するシステムの作成を目的としている。[1] でレビューを参考になる順序に並び替えているように、本研究では後述する提案手法により商品との関連性が高い順にコメントを並び替え、他のユーザーがその商品の購入を検討する際に参考にするコメントを取得しやすいシステムの作成を目指す。また、作成したシステムにより抽出した商品との関連性が高いコメントが、人手の評価に対してどれほどの精度で抽出できているかを評価し、最終的な提案手法の精度としている。

第II部

提案手法

第II部では本研究の提案手法, 及び提案手法で用いている主要な技術について説明する.

4 トピックモデル

提案手法の説明に先立ち, 本提案手法において主要な技術であるトピックモデルについて説明する. トピックモデルとは,

4.1 Latent Dirichlet Allocation

LDA の説明

4.2 Biterm Topic Model

BTM の説明

5 提案手法

ここでは、前項で説明した Bitem Topic Model を用いて、YouTube 上で自社製品やサービスを宣伝している動画に対するユーザーのコメントから、宣伝している商品やサービスに対して関連性が高いコメントを抽出するシステムを提案する。また、提案したシステムの精度を検証する方法についても説明する。

5.1 データ収集

実験に用いる YouTube のコメントは、YouTube Data API v3 を用いて取得した。YouTube Data API v3 は Google Cloud Console で API キーを作成し、API を有効化することで様々な YouTube データにアクセスすることが可能になる。そのうち、YouTube のコメントに関連するものとして表 3 のようなデータが挙げられる。

表 3: YouTube Data API v3 で取得できるコメント情報

項目	内容
videoID	コメントした動画の ID
textDisplay	現在表示されているコメント
textOriginal	最初に投稿されているコメント
authorDisplayName	コメント投稿者の名前
authorProfileImageUrl	コメント投稿者のアイコン
authorChannelUrl	コメント投稿者のチャンネル
authorChannelId	コメント投稿者のチャンネル ID
likeCount	コメントに付いたいいねの数
publishedAt	コメントの投稿日
updatedAt	コメントの最終更新日

本研究では、表 3 のうち textDisplay(現在表示されているコメント)のみを抽出し、実験を行なった。また、YouTube のコメントには元のコメントの他に別のユーザーが返信しているケースも多いが、本研究では返信しているコメントは扱わず、元のコメントのみを抽出し実験の対象としている。抽出したコメントの一例を図 4 に示す。

絶対食べたい😋お腹すいた(´ω`)
本当に...幸せそうな人を見るのって、こっちまで幸せな気持ちになるからいいよなあ.....!!!!!! ☺
好きなことをして生きていくのがYouTuber
本当に努力の塊でしかない💪♥HIKAKINさんが頂点で本当によかったああああああ😭😭😭
新幹線代往復4万ちょい払ってでも『みそる』🍣食べに行きたい

図 4: 抽出したコメントの一例

5.2 前処理手法

トピックモデルを含む自然言語処理の様々な手法において、テキストデータに対する前処理は非常に重要である。Web テキストを扱う場合には HTML タグや JavaScript のコードが含まれることもあり、前処理としてそのようなノイズを除去する必要がある。また、本研究では YouTube の動画に対するコメントをテキストデータとして扱うが、YouTube のコメントや SNS の投稿には絵文字や顔文字、URL、話し言葉などを含んでいることが多い。そのため、本研究でもトピックモデルによる分類を行う前の前処理は非常に重要である。本研究で行った主な前処理とその簡単な説明を以下に示す。

5.2.1 クリーニング処理

空白、改行文字を削除

半角空白や全角空白、及び“\n”などの改行文字を空文字に変換する。

例：「おはよう　今日はいい天気ですね」→「おはよう今日はいい天気ですね」

記号除去

“!”や“#”，及び全角記号を除去する。また、YouTube のコメントの特性上顔文字が使われることも多いため、それらを除去する目的でもある。

例：「今晚、友達と映画を見に行く予定です！ 楽しみです (^ ω ^)」→「今晚友達と映画を見に行く予定です楽しみです」

絵文字除去

顔文字と同様に YouTube のコメントで使われることが多い。感情分析などでは絵文字から情報を取得することもあるが、本研究では感情に関する情報の抽出、分析は行わないため絵文字は除去する。

数字を 0 に置換

自然言語処理の様々な手法において、数字は意味を為さないことが多いため、1 つ以上連続している数字を全て 0 に置換することが多い。本研究でも数字に関する情報を必要としないため、数字はすべて 0 に置換する。

例：「目標は年間で 10 回のイベントを開催することです」→「目標は年間で 0 回のイベントを開催することです」

単語の正規化

単語の正規化とは、単語の文字種の統一、つづりや表記ゆれなどを無くすことである。この処理を行うことで同じ意味で異なる表記や形態の単語が同じ形になり、テキストの処理や解析が容易になる。単語の正規化にはいくつか種類があり、例えば

- テキスト内のアルファベットを全て小文字に変換する
- 半角カナを全角に統一する
- 辞書を用いた単語の統一

などがある。

例：「Google で初の写真を検索してください」→「google でネコの写真を検索してください」

連続長音記号除去, 繰り返し文字のまとめ

話し言葉や若者言葉でよくある「きたーーーーー」や「うおおおおお」など, 連続して長音記号が含まれている場合や同じ単語が繰り返されているものを削除, または一つにまとめる処理を行った.

例:「食べたーーーーい!!」→「食べたーい」

その他の前処理

スパムの可能性があるため, URL を含むコメントを削除した. また, YouTube の特性上外国人のコメントも多く存在したため, 日本語と英語以外の言語を含んでいるコメントを削除した.

以上の前処理を図 4 のコメントに適用した結果を図 5 に示す.

絶対食べたいお腹すいた
本当に幸せそうな人を見るのってこっちまで幸せな気持ちになるからいいなあ
好きなことをして生きていくのがyoutuber
本当に努力の塊でしかないhikakinさんが頂点で本当によかったあ
新幹線代往復0万ちょい払ってでもみそる食べに行きたい

図 5: 前処理後のコメント

5.2.2 MeCab による形態素解析及び分かち書き

次に, トピックモデルで学習する際に必要な文章の分かち書きを行う. 分かち書きとは, 自然言語処理の様々な手法において文章を単語や形態素などの最小単位に分割する処理のことである. この処理を行うことで, 言語解析や機械学習の際にテキストをより扱いやすい形態で実験を行うことができる. また, 英文の場合は単語間にスペースが明示的に存在するため分かち書きは必要ない場合が多いが, 日本語に関しては単語間のスペースがなく, 文章を単語単位に分割する処理を行わないと機械が単語を認識し解析することが難しくなるため, 分かち書きが必要である.

本研究では MeCab[参考文献] を利用して形態素解析, 及び分かち書きを行った. MeCab は京都大学情報学研究科と日本電信電話株式会社コミュニケーション科学基礎研究所の共同研究で開発されたオープンソースの日本語形態素解析エンジンであり, 日本語の文法や単語の品詞情報をもとに文章を形態素に分解したり, 品詞の付与などが可能である. 本研究では MeCab を利用して対象のコメントに対して形態素解析を行い, 形態素に分割後スペース区切りで繋ぐことで分かち書きを行う. MeCab には最初から分かち書きを行う機能も含まれているが, 形態素解析によって抽出した品詞をストップワード除去に用いるためこの手法で分かち書きを行う.

また, 形態素解析の精度はエンジンのアルゴリズムの精度に加え, 形態素解析辞書の精度にも左右される. そのため, 形態素解析の目的にあった辞書を指定し, 解析することが重要となる. 表 4 は MeCab で形態素解析を行うときに主に用いられている辞書を比較したものである. 通常, MeCab での形態素解析には標準搭載されている mecab-ipadic を用いるが, mecab-ipadic は基本的な文法や専門用語に強い反面, 辞書の更新がないため新しい単語や固有表現に弱いという特徴がある. 本研究の分析対象である YouTube の動画に対するコメントは比較的新しい言葉や固有名詞などを含むことが多いため, mecab-ipadic に多数の web 上の言語資源から得た新語を追加し, カスタマイズした mecab-ipadic-NEologd を本研究では形態素解析の辞書に用いている.

表 4: 形態素解析辞書の比較

形態素解析辞書	特徴
mecab-ipadic	IPA コーパスをもとにした MeCab に標準搭載されている IPA 辞書. 基本的な日本語の文法や専門用語などの固有名詞に強いが, 辞書の更新がないため新しい言葉や固有名詞に弱い.
UniDic-mecab	言語学・国語学や音声情報処理など, より多様な目的に適した辞書. 「短単位」という揺れが少ない齊一な単位を見出し語に採用している.
mecab-ipadic-NEologd	多数の web 上の言語資源から得た新語を追加しカスタマイズした MeCab 用のシステム辞書. 辞書の更新が行われるので, 新しい固有表現に強い.

MeCab による形態素解析, 及び分かち書きの処理を行った後, 2.2 節で述べた通り品詞によるストップワード除去を行う. さらに一般的なストップワードリストを用いたストップワード除去を組み合わせることで, 最終的に実験に用いるテキストの形式として整形する. 品詞によるストップワード除去では, 助詞・助動詞などのトピック分類に必要な品詞を除く手法や, 名詞・形容詞などのトピックにかかわる品詞を抽出する手法で行う. 図 6 では mecab-ipadic と mecab-ipadic-NEologd で形態素解析した結果を比較している. 例えば, 近年登場した少年漫画である「鬼滅の刃」という単語を含む文章を形態素解析した場合, mecab-ipadic では“鬼”“滅”“の”“刃”と分割されてしまっているが, 辞書の更新が行われる mecab-ipadic-NEologd では“鬼滅の刃”と一単語で認識されていて, 適切な形態素解析が行われていると言える.




図 6: 辞書による形態素解析結果の比較

5.3 BTM によるトピック抽出

前処理及び分かち書きを行ったテキストデータに対し, 4.2 節で説明した Biterm Topic Model を適用する. BTM を適用することでテキストデータに存在する潜在的なトピックをハイパーパラメータで指定した数だけ推定し, トピックごとに出現しやすい単語を抽出する.

5.4 文章生成

次に、各トピックごとの出現確率上位の単語を抽出した結果を用いて、各トピックごとに文章を自動で生成する。抽出した単語は各トピックの出現確率上位の単語であるため、ここで生成された文章は各トピックごとに代表的であるという仮説を立て、以降の手法に適用する。文章を自動で生成する方法として、大規模言語モデルである GPT-4 を搭載した ChatGPT を用いる方法で行った。プロンプトには以下のルールを入力して各トピックごとに文章を生成した。

抽出した単語を空白区切りで入力する

BTM によって抽出した n 単語 (n は抽出する単語数) を空白区切りで入力する。ChatGPT に正しく単語を認識させるため、空白区切りにする必要がある。

全ての単語を使用する

抽出した単語を全て使用することで、後述する類似度計算の精度を向上させる。

人名がある場合は指定する

人名を ChatGPT が認識できない場合、文章が支離滅裂になる可能性があるため個別に指定する。

一つの文章に多くの単語を用いて、文章数は少なくする

生成される文章はトピックごとに代表的であるという仮説の元、YouTube のコメントの特徴に近い文章を生成したいため、長文を避けるようなルールを追加している。

YouTube のコメントのように生成する

人が投稿するコメントに近い文章を生成する。

図 7 に ChatGPT に入力する単語、プロンプト、出力結果の例を示す。提案手法では各トピックごとに文章を生成するため、図 7 のような結果がトピックの数だけ生成される。

n=10の例

入力単語例：「味噌 ラーメン 美味しい 味 濃厚 感動 ヒカキン 購入 笑顔 麺」

プロンプト例

- ・以下のルールに従って文章を生成してください
- ・空白区切りで入力した単語を使用してください
- ・全ての単語を使用してください
- ・"ヒカキン"は人名として扱ってください
- ・出来る限り短い文章を生成してください
- ・YouTubeのコメントのような文章を生成してください



出力例

「ヒカキンが見つけた味噌ラーメンは驚くほど美味しい！濃厚な味わいの麺が、彼の笑顔と共に感動を呼び起こします。」

図 7: ChatGPT を用いた文章生成例

5.5 文章間の類似度計算

前節で ChatGPT を用いて自動で生成した文章と、5.2.1 節で述べたクリーニング処理を施した YouTube の元コメントとの文章間の類似度を計算し、数値が高い順に並び替えることで、本研究の目的である、YouTube 上で自社製品やサービスを宣伝している動画に対するコメントのうち他のユーザーがその商品の購入を検討する際に参考にできるようなコメントの抽出を実現する。文章間の類似度計算手法には Cos 類似度を用いる。Cos 類似度とは、二つのベクトルが「どれくらい似ているか」を表す尺度であり、二つのベクトルがなす角の Cos 値のことである。Cos 類似度は、式 (3) のように二つのベクトルの内積を二つのベクトルのノルムで割ることで求められる。

$$\text{Cosine Similarity} = \frac{\mathbf{A} \cdot \mathbf{B}}{\|\mathbf{A}\| \|\mathbf{B}\|} \quad (3)$$

前節で生成した文章は、元のコメント集合から抽出した潜在的なトピックごとの代表的な文章であるという仮説を立てていることから、生成した文章との文章間の Cos 類似度が高い YouTube の元コメントはそのトピックとの関連性が高い文章といえる。また、本研究では抽出したトピックにラベル付けを行わないため、どのようなトピックとの関連性が高いかは判断することができない。しかし本節で行う類似度計算では生成したトピック数の文章全て ($k=5$ であれば 5 文全て) と元のコメント一文との Cos 類似度をそれぞれ計算し、一番高い数値をその文章の類似度として扱うため、具体的に何に関するトピックかは判断できないが動画内容との関連性を数値で示すことができると考えた。

Cos 類似度は二つのベクトルの類似度を計算するため、本手法に用いる上で文章をベクトル化する必要がある。文章をベクトル化する手法は数多く存在するため、目的によって適切な手法を選択することが重要である。本研究では、単語の重要度を考慮できる TF-IDF による文章のベクトル化と、様々なタスクに適用できる汎用性を持つ BERT の事前学習済みモデルを用いた文章の埋め込み (ベクトル化) の二つの手法で実験を行う。

5.5.1 TF-IDF

TF-IDF とは、Term Frequency(単語頻度) と Inverse Document Frequency(逆文書頻度) の積で定義される、文書中のある単語の重要度を表す指標である。TF は「一つの文書 d に単語 t がどれだけの割合で出現したか」を定量的に表した指標であり、式 (4) で表せられる。ここで、 $n_{d,t}$ は文書 d 中に単語 t が出現する回数、 T は一つの文書における単語数の合計である。

$$TF_{d,t} = \frac{n_{d,t}}{\sum_{t=1}^T n_{d,t}} \quad (4)$$

IDF は「ある単語を含む文書が文書集合の中でどれくらいの割合を占めているか」を定量的に表した指標であり、実際の式 (5) ではその割合の逆数の対数を取っている。つまり、「ある単語が一部の文書にしか現れない度合い」を計算していることとなる。ここで、 N は全体の文書数、 df_t は単語 t が出現する文書数を表す。

$$IDF_t = \log \frac{N}{df_t} \quad (5)$$

TF-IDF は式 (6) のように TF(式 (4)) と IDF(式 (5)) の積で表せられる。

$$TF\text{-}IDF_{d,t} = TF_{d,t} \times IDF_t \quad (6)$$

従って、TF-IDF は以下の条件のときに高い数値を示す。

- その単語の単語頻度が高い
- 文書集合全体に対して、その単語の文書頻度が低い

この計算を全ての文書、単語に対して行うことで文書に含まれる単語の重要度から文書の特徴を定量的に求めることができる。そして、各単語に対する TF-IDF 値を要素としたベクトルを生成し、Cos 類似度の計算に用いる。

5.5.2 BERT

BERT(Bidirectional Encoder Representations from Transformers) は Google によって 2018 年に開発された Transformer をベースとした自然言語処理モデルである。従来の自然言語処理モデルでは文章を前から読み文脈を理解していくのに対して、BERT では Masked Language Model(MLM) というモデルを使用することで文章を文頭と文末の双方向から学習している。MLM ではテキストの一部を [MASK] という別の単語で置き換えたテキストを入力し、その前後の文脈に基づいて [MASK] の単語を予測するようにモデルを訓練する。文章を双方向から学習することにより、ある単語の前後の文脈を捉えることができ自然言語処理モデルとしての性能を大幅に向上させた。加えて、文単位での学習を行う Next Sentence Prediction(NSP) という手法を組み合わせることでさらにモデルの性能を向上させている。NSP は二つの文章の関係性について予測するタスクであり、二つの文章を入力した後に「二つの文章は連続しているかどうか」を判定するタスクを繰り返すことで学習を行う。図に示すように、二つの文章が連続している場合は IsNext、そうでない場合は NotNext の判定を行う。各入力の最初にある [CLS] トークンは主に分類タスクにおいて使用され、[CLS] トークンに関連付けられた隠れ層の状態 (ベクトル) が入力文の全体的な意味を捉えるようになる。また、[SEP] は文の区切りを示している。この NSP という手法により、単語だけではなく文章のつながりに関して学習することができる。

Input = [CLS] 私は [MASK] を読んでいます。[SEP] それはとても [MASK] です。[SEP] Label = IsNext
Input = [CLS] 昨日、私は新しい [MASK] を買った。[SEP] 木星は [MASK] の中で最大の惑星です。[SEP] Label = NotNext

図 8: NSP による文章のつながり判定例

本研究では、この BERT モデルを用いた文章の埋め込み (ベクトル化) を行い、Cos 類似度の計算に用いている。BERT モデルでは、テキストを前処理した後トークン化する。BERT におけるトークン化は通常の単語分割よりも複雑な場合があり、例えば単語本体と接頭辞、接尾辞に分割するサブワード分割を行うことがある (例: “playing” → [“play”, “#ing”])。また、BERT の出力は入力された各トークンに対する文脈依存の埋め込みである。これらの埋め込みは単語の意味がその文脈によってどのように変化するかを捉えることができる。例えば、「この部屋は明るい」と「彼は明るい性格だ」では「明るい」の意味が異なり、文章埋め込みの出力結果も異なる。このように BERT モデルを使用した文章の埋め込みでは、文章を双方向から学習することで文脈の理解において高い精度を示したり、単語の意味の差異を理解し適切な結果を出力したりできる。この BERT モデルを使用した文章のベクトル化と、先述した TF-IDF を用いた手法とを比較して実験を行い、本研究の目的に対してより効果的な手法がどちらなのかを検証する。

5.6 提案手法の精度検証

前節までの提案手法によるシステムの妥当性、及び精度を検証するため、人手で評価したデータとの比較を行う。人手による評価として、5.2.1 節で述べたクリーニング処理を施した元のコメント文に対して、動画で宣伝している商品やサービスに関連しているかどうかを人手でアノテーションし、ラベル付けを行う。アノテーションの基準として以下のようなルールに当てはまるコメントに「関連性-高」のラベルを付け、その他のコメントに「関連性-低」のラベルを付与し、正解ラベルが付いたデータを作成する。

- 動画で宣伝している商品やサービスに直接関係している
- 商品やサービスに対する視聴者の意見・感情などを含んでいる
- 商品やサービスを宣伝している動画内容に関係している

「関連性-高 / 低」の二値分類を行った結果から、「関連性-高」ラベルを付けたコメントの件数を a、「関連性-低」ラベルを付けたコメントの件数を b とする。そして、前節で文章間の類似度を計算し降順にソートしたテキストデータの上位 a 件を「関連性-高」と予測したデータ、下位 b 件を「関連性-低」と予測したデータとみなし、正解ラベルを付与したデータと予測データに対して Confusion Matrix (混同行列) を求める。Confusion Matrix とは、二値分類問題で出力された結果をまとめた行列 (≒表) のことで、機械学習モデルの性能を測る指標として用いられていることが多い。本研究では、「関連性-高 / 低」の二値分類に関して、提案手法により予測したデータを機械学習モデルで予測したデータとみなし、Confusion Matrix を求める。

図 9 が一般的な機械学習モデルにおける Confusion Matrix である。行が正解のクラス (ラベル) を、列が機械学習モデルで予測したクラス (ラベル) を表している。TP (True Positive) は Positive ラベルが付いているものを正しく「Positive」だと予測していて、注目対象を正しく分類できる、また対処すべき注目事象を特定できることを表す。TN (True Negative) は Negative ラベルが付いているものを正しく「Negative」だと予測していて、注目対象以外を正しく分類できる、また注目対象を見逃さず損失を避けられることを表す。FN (False Negative) は Positive ラベルが付いているものを誤って「Negative」だと予測していて、注目対象を誤ってそれ以外に分類してしまう、また注目対象を見逃し利益の獲得を逃してしまうことを表す。FP (False Positive) は Negative ラベル

が付いているものを誤って「Positive」だと予測していて、注目すべきではないものを誤って分類してしまう、また分類する事象によっては無駄なコストがかかることを表す。これらを使い、機械学習モデルの性能を測る様々な指標を計算することができる。

		機械学習モデルの予測	
		Positive	Negative
実際の正解ラベル	Positive	TP(True Positive) Positiveと判定し、それが正解	FN(False Negative) Positiveと判定したが、実際はNegative
	Negative	FP(False Positive) Negativeと判定したが、実際はPositive	TN(True Negative) Negativeと判定し、それが正解

図 9: Confusion Matrix

以下に図 9 の Confusion Matrix の例から求められる様々な指標を示す。

Accuracy

正解率・正確度・精度などと呼ばれ、全予測結果の中で正しい予測をしたもの (TP・TN) の割合のこと。総合的なモデルの性能を示すのに用いられることが多いが、クラスに偏りがある場合 (例：Positive が極端に多く、Negative が極端に少ない)、はモデルの性能を正しく評価できないこともある。

$$\text{Accuracy} = \frac{TP + TN}{TP + FP + FN + TN}$$

Error Rate

不正解率と呼ばれ、Accuracy の逆で全予測結果の中で誤った予測をしたもの (FP・FN) の割合のこと。Accuracy と同様に、クラスの偏りがある場合にはモデルの性能を正しく評価できないこともある。

$$\text{Error Rate} = \frac{FP + FN}{TP + FP + FN + TN}$$

Sensitivity・Recall

感度・再現率・検出率などと呼ばれ、正解クラスが Positive であるとき、予測モデルも Positive だと判定した割合のこと。実際に正解クラス (例：癌の検出など) を見逃さないことが重要な事象の際に重視される指標である。

$$\text{Sensitivity} \cdot \text{Recall} = \frac{TP}{TP + FN}$$

Specificity

特異度と呼ばれ, 正解が Negative であるとき, 予測モデルも Negative だと判定した割合のこと. 疫病検査の例では, 罹患していない人の結果が陰性となる率であり, 負のケースを正確に識別することが重要な事象の際に重視される.

$$\text{Specificity} = \frac{TN}{FP + TN}$$

Precision

適合率と呼ばれ, モデルが Positive と予測したときに実際にそれが Positive である割合のこと. 偽正例 (誤った正の予測) を最小限に抑えたい事象のときに重視される指標である.

$$\text{Precision} = \frac{TP}{TP + FP}$$

F1-measure

F1 値・F 値などと呼ばれ, Precision(適合率) と Recall(再現率) の調和平均のことである. 一般的に Precision と Recall の間にはトレードオフの関係があるが, そのバランスを取る必要がある事象のときに重視される指標である.

$$\text{F1-measure} = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2 \times TP}{2 \times TP + FP + FN}$$

このように Confusion Matrix を使用した機械学習モデルの性能評価には様々な指標が存在するが, どの指標がそのモデル・目的に対して最適な性能評価を行えるかどうかの判断を行う必要がある. 図 10 は本研究における Confusion Matrix を示している.

		提案手法の予測	
		関連性がある コメント	関連性がない コメント
人手によって アノテーション したクラス	関連性がある コメント	TP(True Positive) 関連性ありと判定し, それが正解	FN(False Negative) 関連性ありと判定したが, 実際は関連性なし
	関連性がない コメント	FP(False Positive) 関連性なしと判定したが, 実際は関連性あり	TN(True Negative) 関連性なしと判定し, それが正解

図 10: 提案手法の Confusion Matrix

第III部

実験結果

6 実験目的、仮説

第IV部

参考文献

- [1] 機械学習を用いた自然言語処理による商品レビューの評価
- [2] 単語の出現頻度と類似性に基づいたトピックモデル洗練化手法